Engenharia e Ciência de Dados

18 de outubro de 2025

Meta 1
PLN

Trabalho realizado por:

Beatriz Martins - 2023210538; uc2023210538@student.uc.pt

Laura Barreto - 2023214375; uc2023214375@student.uc.pt

Introdução

Para este trabalho, o dataset escolhido foi “factnews_dataset.csv”, por ser aquele que considerámos mais desafiante de analisar. O dataset tem 7 colunas e 6191 linhas. As suas características são: file (documento onde se encontra a frase), id_sente (ID da frase), id_article (ID do artigo), domain (domínio do artigo: se é de política ou do mundo por exemplo), year (ano em que o artigo foi publicado), sentences (frases para classificar) e classe (classe da frase: se é citação (-1), facto (0) ou viés (1)). O dataset tem **4242** factos, **1391** citações e **558** viés, pelo que dá para entender que está extremamente desbalanceado e que a classe viés será mais difícil de detetar.

Pré-processamento

Antes de começármos a aplicar as regras de classificação por nós criadas, decidimos que seria melhor verificar se existiam linhas duplicadas ou com valores nulos. Como não existiam, passamos à próxima etapa: verificámos que as correlações das colunas de entrada (exceto o file e sentences) com a saída, não eram significativas (estavam entre -0.1 e 0.1).

Dividimos os dados em treino e teste e usamos stratify para garantir que a proporção das classes se mantinha tanto num como no outro (garante que a classe mais pequena não vá toda para o treino ou para o teste), ficando com **2969** citações, **974** factos e **390** viés nos dados de treino.

Depois, adicionámos 3 novas colunas ao dataframe de treino: “tokens”, “doc” e “bigrams”. A primeira contém listas com as palavras das frases mas sem as stopwords, a segunda transforma as frases em objetos spaCy para ser mais fácil de as manipular (e de extrair conhecimento linguístico), e a última contém os bigramas das frases.

Sistema de classificação de frases

De forma a classificar as frases como citações, factos ou viés, decidimos criar três funções (detetar_citacao, detetar_facto e detetar_vies), que retornam o número de condições verificadas em cada classe. No final, a frase é atribuída à classe que devolve o valor mais alto, ou seja, à classe mais provável, por ter verificado a maior quantidade de condições satisfeitas.

Regras comuns a todas as classes

Optámos por usar os adjetivos, advérbios, palavras e verbos mais frequentes de cada classe, pois os restantes elementos testados (entidades, bigramas e funções sintáticas) não permitiam distinguir tão bem as 3 as classes. Para este processo, consideramos apenas as 5 mais frequentes, por ser o número que nos deu melhores resultados. Portanto, se a frase contiver algum dos 5 verbos mais frequentes de uma classe, ou algum dos sinónimos dos lemas desses verbos, aumentamos mais uma condição verificada dessa classe. O mesmo acontece caso a frase contenha os 5 adjetivos, advérbios ou palavras mais frequentes nessa classe.

```
Verbos mais frequentes por classe:
Classe 0: [('ter', 211), ('dizer', 174), ('fazer', 163), ('poder', 96), ('afirmar', 95)]
Classe 1: [('ter', 34), ('fazer', 27), ('poder', 19), ('dever', 15), ('dar', 14)]
Classe -1: [('dizer', 185), ('ter', 142), ('afirmar', 94), ('fazer', 54), ('poder', 49)]
Adjetivos mais frequentes por classe:
Classe 0: [('primeiro', 89), ('segundo', 57), ('maior', 48), ('nova', 47), ('eleitoral', 34)]
Classe 1: [('segundo', 12), ('primeiro', 9), ('eleitoral', 8), ('segunda', 7), ('terceiro', 7)]
Classe -1: [('eleitoral', 17), ('possível', 16), ('melhor', 14), ('primeiro', 12), ('"', 11)]
Advérbios mais frequentes por classe:
Classe 0: [('não', 294), ('mais', 189), ('também', 184), ('já', 110), ('ainda', 97)]
Classe 1: [('não', 60), ('mais', 43), ('também', 29), ('já', 18), ('muito', 12)]
Classe -1: [('não', 236), ('mais', 62), ('sempre', 30), ('muito', 27), ('já', 27)]
Palavras mais frequentes por classe:
Classe 0: [('presidente', 252), ('lula', 223), ('segundo', 199), ('bolsonaro', 197), ('sobre', 143)]
Classe 1: [('bolsonaro', 39), ('lula', 37), ('presidente', 33), ('governo', 26), ('sobre', 25)]
Classe -1: [('disse', 129), ('afirmou', 71), ('lula', 63), ('presidente', 53), ('sobre', 48)]
```

Figura 1 - Elementos mais frequentes nas 3 classes

Verificámos também, que as citações apresentam mais aspas do que os factos e os viés: a média do número de aspas nas citações é 1, enquanto nas outras classes é 0. Este padrão constitui um bom indicador para distinguir citações, já que factos e viés raramente contêm aspas. Assim, definimos a seguinte regra: se a frase contiver uma aspa, incrementa-se a contagem da classe **Citação**. Caso não tenha, incrementa-se a contagem das classes **Facto** e **Viés**.

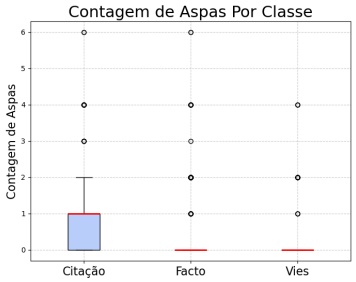

Figura 2 - Distribuição do número de aspas nas frases de cada classe

Regras adicionais na classe Viés

Começámos por testar a polaridade das frases, para perceber se a classe viés poderia ter um maior número de palavras numa frase com um carácter negativo ou pejorativo, já que normalmente são frases de opinião ou julgamento. Usámos o dataset "Sentilex.csv" com 82347 palavras e a sua polaridade, guardando esses valores num dicionário em que as chaves eram as palavras e o valor era a sua polaridade. No entanto, verificámos que havia mais frases classificadas como negativas em todas as classes, como mostra a figura 3.

```
CLASSE:  -1 ;Negativas:  684 ; Neutras:  98 Positivas:  192
CLASSE:  0 ;Negativas:  2101 ; Neutras:  335 Positivas:  533
CLASSE:  1 ;Negativas:  259 ; Neutras:  48 Positivas:  83
```

Figura 3 - Distribuição do número de frases negativas, neutras e positivas de cada classe

Em alternativa, analisámos a frequência de palavras negativas nas frases das três classes e concluímos que o viés tende a apresentar uma frequência ligeiramente mais elevada, embora, de forma geral, palavras negativas apareçam muito pouco em todas as classes. Isto sugere que o dataset SentiLex contém poucas palavras que se repetem com frequência no nosso dataset FactNews, como "presidente" e "Lula", o que confirmámos ser verdade. Para contornar esta limitação, adicionámos uma regra na função detetar_vies: se a frequência de palavras negativas ultrapassar 0,075 (valor máximo da classe facto sem considerar outliers) incrementa-se 1 às condições da classe viés, pois acima desse limiar apenas ocorrem exemplos dessa classe (ignorando outliers).

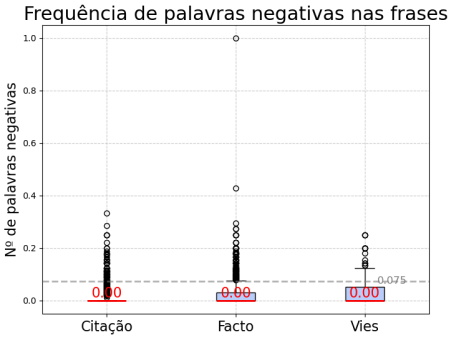

Figura 4 - Distribuição da frequência de palavras negativas nas frases de cada classe

Adotámos ainda outra estratégia: criámos listas de palavras negativas, positivas e neutras para todas as classes, removendo da classe viés aquelas que também apareciam nas outras classes. Desta forma, obtivemos listas exclusivas de palavras representativas da classe viés. Em seguida, acrescentámos três condições nessa classe, que verificam se a frase contém alguma das palavras exclusivas das listas negativa, positiva e neutra, incrementando a contagem de condições verificadas sempre que tal acontece.

Outra regra criada relaciona-se com a contagem de adjetivos, advérbios, letras maiúsculas após uma aspa e palavras de uma frase. Após verificar os boxplots da figura 5, obtivemos, então a seguinte regra na classe viés: se o número de adjetivos, advérbios e de letras maiúsculas após uma aspa for maior ou igual do que 4 e a contagem de palavras nas frases for superior a 18, então verificamos mais uma condição na classe viés (estes valores foram os que nos pareceram obter melhores resultados mais à frente). Decidimos testar o número de palavras, advérbios, adjetivos e maiúsculas, porque achámos que as classes facto e citação teriam valores menores (no caso do facto por ser geralmente mais objetivo) e a classe viés teria valores mais altos, já que é constituída por frases tendenciosas ou opinativas.

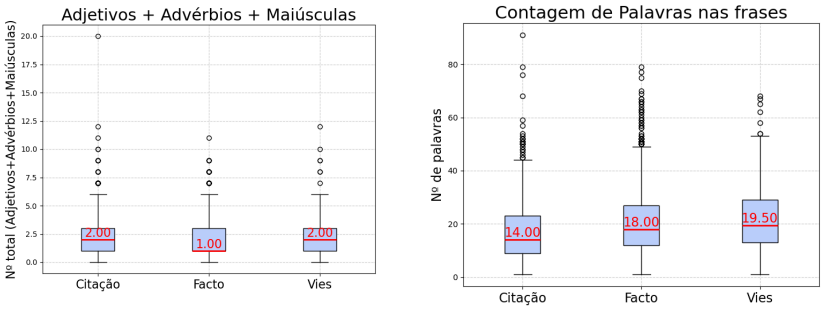

Figura 5 - Distribuição do número de adjetivos, advérbios e maiúsculas antes de uma aspa e do número de palavras nas frases de cada classe

Resultados e Discussão

Usando as regras descritas anteriormente, e atribuindo a cada uma delas o mesmo peso de 1, caso a condição seja verificada, obtemos a seguinte matriz de confusão e classification report.

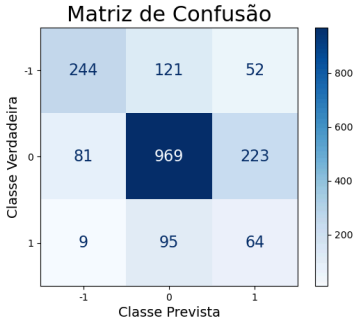

	precision	recall	f1-score	support
-1	0.73	0.59	0.65	417
0	0.82	0.76	0.79	1273
1	0.19	0.38	0.25	168
accuracy			0.69	1858
macro avg	0.58	0.58	0.56	1858
weighted avg	0.74	0.69	0.71	1858

Figura 6 - Resultados das métricas atribuindo peso 1 a todas as regras

No entanto, decidimos experimentar uma abordagem alternativa: implementamos manualmente o grid search para descobrir a melhor combinação de pesos de cada regra, de forma a maximizar a métrica F1-macro das três classes, evitando assim dar demasiada importância às classes mais numerosas. Para isso, testámos todas as combinações possíveis dos pesos 0.5, 1 e 2 para as várias regras, mantendo o peso das aspas em 2, por ser uma regra extremamente eficaz a distinguir citações, e fixando os pesos das palavras negativas, neutras e positivas exclusivas na classe viés em 0.5, devido à sua baixa frequência nesta classe.

```
Melhor combinação: {'peso_verbos': 1, 'peso_adverbios': 0.5, 'peso_adjetivos': 2, 'peso_palavras': 1, 'peso_freq_neg': 0.5, 'peso_comb_vies': 0.5}
Melhor média de F1: 0.5718903815028734
```

Figura 7 - Pesos atribuídos às regras pelo grid search

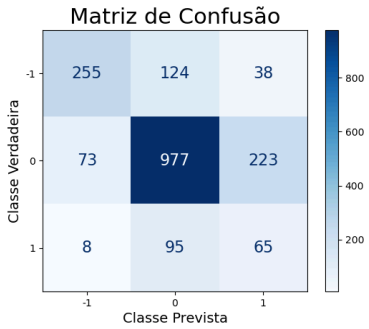

	precision	recall	f1-score	support
-1	0.76	0.61	0.68	417
0	0.82	0.77	0.79	1273
1	0.20	0.39	0.26	168
accuracy			0.70	1858
macro avg	0.59	0.59	0.58	1858
weighted avg	0.75	0.70	0.72	1858

Figura 8 - Resultados das métricas atribuindo os pesos provenientes do grid search

Ao comparar as duas abordagens, podemos concluir que houve um aumento na métrica f1 score de 3% e 1% na classe citação e viés respetivamente, e um aumento de 1% na accuracy geral. Já as métricas dos factos não aumentaram muito. Embora não tenha havido uma maximização muito grande, podemos perceber que as regras que são mais significativas na distinção das classes são os adjetivos e os verbos mais frequentes em cada uma delas. As regras mais fracas, a que o grid search atribuiu um peso de 0.5 são: os advérbios mais frequentes; a frequência de palavras negativas nas frases do viés e a combinação de advérbios, adjetivos, maiúsculas após uma aspa e número de palavras nas frases.

Como é possível observar na figura 8, conseguimos classificar muito melhor a classe 0 e a classe -1, comparativamente à classe 1. Isto deve-se ao facto desta ter um menor número de amostras e necessitar de regras mais específicas para a distinguir. Para além disso, 223 frases desta classe são confundidas com as da classe 0, sendo falsos positivos. No entanto, tendo em conta todas as dificuldades, ainda conseguimos resultados mais ou menos satisfatórios para esta classe. Portanto de 417 citações detetámos 255, de 1273 factos detetámos 977 e de 168 viés detetámos 65. Tanto nos factos como citações a precision é mais alta que o recall, logo há mais falsos negativos do que falsos positivos nessas classes, o que não é tão problemático dado o tema do dataset não ser saúde por exemplo.

Conclusão

Uma das maiores dificuldades com que nos deparámos ao longo de todo este trabalho, está relacionada com, não só o desbalanceamento do dataset, mas também com o facto de existirem frases que achamos que estão mal classificadas no próprio dataset, ou que apenas se saberia que pertenceriam a uma classe através do contexto em que se inserem no artigo. Um exemplo é a frase: “Não reajusta a merenda escolar, mas gasta milhões com leite condensado;” que nós classificaríamos como viés (1) mas que está como citação (-1) no dataset. Após alguma pesquisa foi possível concluir que essa frase fazia parte de uma citação, mas sem contexto, seria impossível saber.

Concluindo, este trabalho permitiu-nos aprender um pouco de tudo relacionado com Processamento de Linguagem Natural e conseguimos entender o quão complexo é fazer a distinção de diferentes tipos de frases.

Referências:

- https://realpython.com/python-nltk-sentiment-analysis/
- https://realpython.com/sentiment-analysis-python/
- https://www.kaggle.com/code/krutarthhd/sentiment-classification-using-spacy
- https://www.linkedin.com/pulse/spacy-sentiment-analysis-easy-way-analyze-text-vitor-mesquita-zo83f
- https://spacy.io/usage/spacy-101
- https://spacy.io/api/textcategorizer
- https://wandb.ai/authors/Kaggle-NLP/reports/Kaggle-s-NLP-Text-Classification--VmlldzoxOTcwNTc
- https://spacy.io/models/pt
- https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.CountVectorizer.html
- https://medium.com/@johnidouglasmarangon/building-a-text-classification-model-with-spacy-3-x-57e59fa50547
- https://www.nltk.org/howto/wordnet.html