Engenharia e Ciência de Dados

6 de novembro de 2025

Meta II

PLN

Trabalho realizado por:

Beatriz Martins - 2023210538; uc2023210538@student.uc.pt

Laura Barreto - 2023214375; uc2023214375@student.uc.pt

Introdução

➡ Neste trabalho iremos aplicar modelos como o KNN, Regressão Logística e Redes Neuronais entre outros, às matrizes com colunas numéricas baseadas nas nossas regras do primeiro trabalho e às matrizes de features linguísticas obtidas com o TF-IDF, GloVe e BERT.

➡ No caso da matriz das nossas regras, testámos quatro formas distintas: dados balanceados e não balanceados, com todas as colunas ou apenas as mais correlacionadas com a saída.

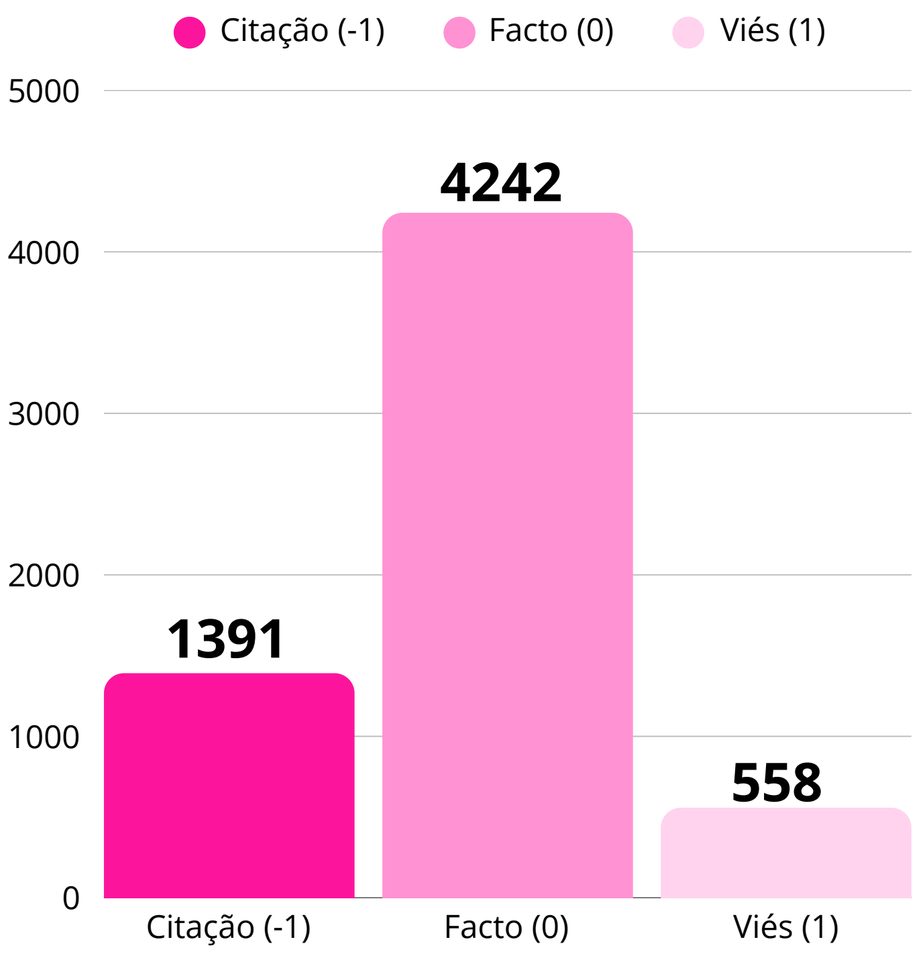

Figura 1 - Distribuição das classes Viés, Facto e Citação

Pré-processamento

Comum a todas as abordagens:

➡ Divisão dos dados em treino, validação e teste

Apenas para os ficheiros de regras:

➡ Correlações entre as diferentes colunas e a saída

➡ Criação de coluna de tokens

➡ Adição de uma coluna para cada regra diferente

```
colunas = [
    "so_vies_pos", "so_vies_neg", "so_vies_neu",
    "so_facto_pos", "so_facto_neg", "so_facto_neu",
    "so_citacao_pos", "so_citacao_neg", "so_citacao_neu",
    "adj_vies", "adj_facto", "adj_citacao", "adv_vies",
    "adv_facto", "adv_citacao", "num_aspas", "num_palavras",
    "top5_palavras_vies", "top5_palavras_facto", "top5_palavras_citacao"
]
```

Figura 2 - Colunas nos Dataframes de regras (a vermelho assinaladas as que têm maior correlação com a saída)

Para os ficheiros de regras e GloVe:

➡ Remoção de stop words

Apenas para os ficheiros de regras balanceados:

➡ SMOTE e undersampling para aumentar o tamanho das classes mais pequenas e diminuir o tamanho da maior para 1000 (apenas no treino, tanto na fase de validação como na fase de teste)

Apenas para os ficheiros nbal_corr e bal_corr:

➡ Escolha apenas das colunas mais correlacionadas com a saída (acima de 0.20 ou abaixo de -0.20)

Divisão do conjunto de dados

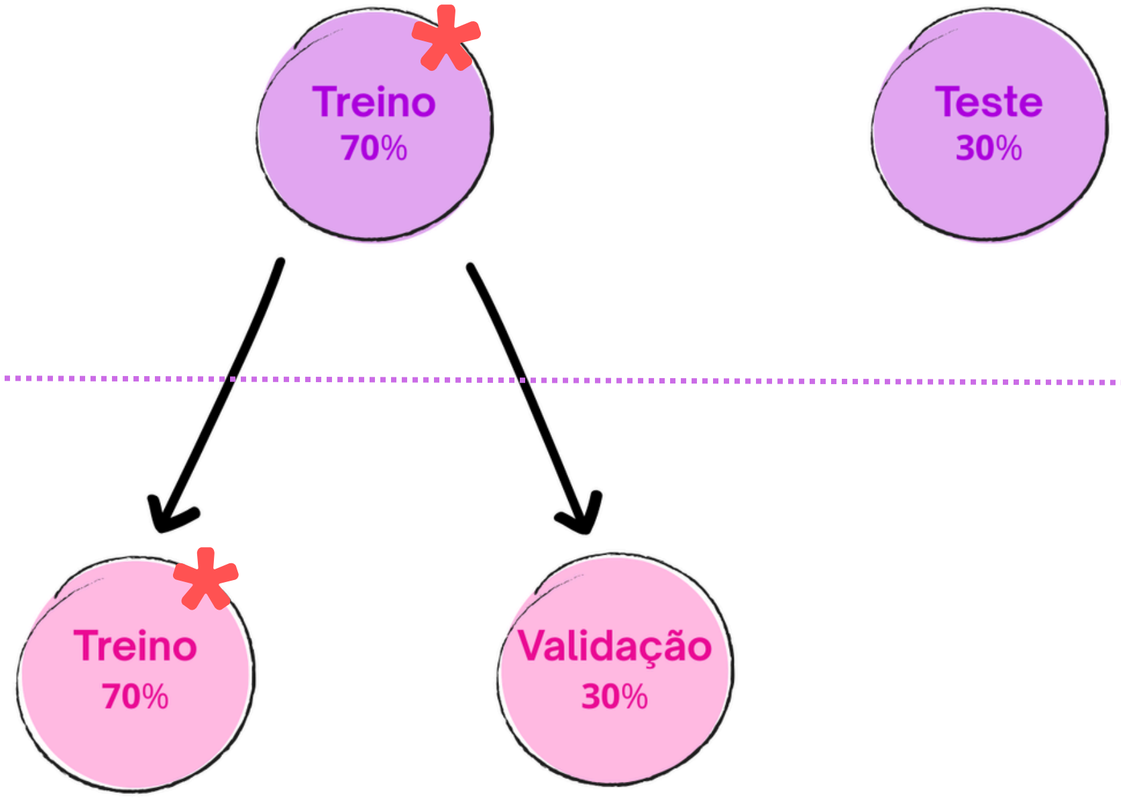

Figura 3 - Divisão dos dados em treino, teste e validação

Fase 2: Treinar o dataset de treino completo usando os melhores parâmetros e testar nos dados de teste obtendo as métricas finais.

Fase 1: Usámos Optuna para testar vários parâmetros nos modelos avaliando-os com as métricas no dataset de validação, em especial o F1-Score macro.

* No caso dos ficheiros “bal_” apenas estes conjuntos foram balanceados antes de serem treinados nos diversos modelos

KNN

O KNN, para prever a classe de uma amostra, baseia-se nos seus k vizinhos de treino mais próximos, fazendo uma votação entre eles para decidir que classe lhe atribuir, sendo de extrema importância normalizar os dados, uma vez que as distâncias têm em conta a variação dos eixos. Os resultados obtidos em cada abordagem, com os melhores parâmetros estão representados abaixo.

Método	F1 score			Accuracy	Tempo de execução (s)
	Citação	Facto	Viés		
nbal	59%	84%	11%	75%	0,00
bal	60%	61%	20%	53%	0,00
nbal_corr	66%	85%	5%	77%	0,00
bal_corr	37%	0%	6%	23%	0,00
TF-IDF	47%	77%	12%	66%	0,00
GloVe	29%	85%	27%	75%	0,00
BERT	80%	89%	31%	83%	0,01

Tabela 1 - Resultados no modelo KNN

Legenda:

- menor que 30%
- entre 30% e 50%
- entre 50% e 80%
- entre 80% e 90%
- entre 90% e 100%

KNN Discussão

- O modelo não tem tão bom desempenho quando se baseia apenas nas colunas mais correlacionadas com a saída. Isto pode acontecer porque, ao utilizar o conjunto completo de dados, é possível estimar com mais precisão as distâncias aos k vizinhos mais próximos e, assim, determinar com mais segurança a classe da amostra.
- O modelo é extremamente rápido e obteve resultados bastante satisfatórios.
- A abordagem que usa as nossas regras parece ter tido melhor desempenho do que o TF-IDF e o GloVe neste modelo.
- A abordagem BERT foi a que visivelmente obteve melhores resultados em todas as métricas.

Melhor abordagem neste modelo:

BERT

Regressão Logística

A Regressão Logística prevê a classe de uma amostra, calculando a probabilidade de pertencer a cada categoria, usando uma função sigmóide aplicada a uma combinação linear das variáveis. Os resultados obtidos em cada abordagem, com os melhores parâmetros estão representados abaixo.

Método	F1 score			Accuracy	Tempo de execução (s)
	Citação	Facto	Viés		
nbal	57%	84%	11%	75%	0,19
bal	63%	50%	21%	45%	0,01
nbal_corr	40%	82%	5%	71%	0,01
bal_corr	67%	85%	5%	77%	0,00
TF-IDF	58%	84%	10%	75%	0,21
Glove	67%	87%	25%	79%	0,09
BERT	90%	92%	47%	87%	6,93

Tabela 2 - Resultados no modelo da Regressão Logística

Legenda:

- menor que 30%
- entre 30% e 50%
- entre 50% e 80%
- entre 80% e 90%
- entre 90% e 100%

Regressão Logística Discussão

- A abordagem BERT obteve resultados bastante elevados com 87% de accuracy, F1-score igual a 90% na classe citação e acima de 90% na classe facto. Para além disso, quase atingiu os 50% na classe viés, a mais difícil de classificar.
- O modelo teve um melhor desempenho que o KNN em todas as métricas exceto na classe viés (nas abordagens TF-IDF e Glove). Assim, a performance geral do modelo melhorou, mas à custa classificamos pior a classe minoritária.
- O modelo demorou ligeiramente mais tempo a ser treinado do que o KNN, especialmente na abordagem BERT que durou aproximadamente 7 segundos.

Melhor abordagem neste modelo:

BERT

Naïve Bayes

O Naive Bayes é um modelo probabilístico baseado no teorema de Bayes, que assume independência entre as features. Este calcula a probabilidade condicional de pertencer a cada classe, dado o conjunto de atributos da amostra e atribui-lhe a classe com maior probabilidade. Os resultados obtidos em cada abordagem, com os melhores parâmetros estão representados abaixo.

Método	F1 score			Accuracy	Tempo de execução (s)
	Citação	Facto	Viés		
nbal	35%	80%	11%	68%	0,00
bal	22%	81%	11%	69%	0,00
nbal_corr	21%	81%	5%	69%	0,00
bal_corr	17%	81%	5%	69%	0,00
TF-IDF	48%	49%	21%	41%	0,05
Glove	62%	79%	31%	68%	0,00
BERT	76%	83%	40%	75%	0,03

Tabela 3 - Resultados no modelo Naive Bayes

Legenda:

- menor que 30%
- entre 30% e 50%
- entre 50% e 80%
- entre 80% e 90%
- entre 90% e 100%

Naïve Bayes Discussão

- O modelo, por ser mais simples e assumir independência não obteve bons resultados, principalmente no TF-IDF.
- No entanto, no BERT os resultados foram bastante satisfatórios, tendo o terceiro maior valor de F1-score na classe viés de todos os modelos. Desta forma, é um modelo que não é tão afetado pelo desbalanceamento entre classes, no caso da abordagem do Bert.

Melhor abordagem neste modelo:

BERT

Random Forest

O Random Forest é um modelo de ensemble que combina várias decision trees independentes. Cada árvore é treinada com subconjuntos aleatórios dos dados e das features. Depois de todas as árvores fazerem as suas previsões, a decisão final é escolhida pela votação entre elas. Os resultados obtidos em cada abordagem, com os melhores parâmetros estão representados abaixo.

Método	F1 score			Accuracy	Tempo de execução (s)
	Citação	Facto	Viés		
nbal	66%	85%	11%	78%	0,16
bal	64%	52%	20%	47%	0,24
nbal_corr	67%	85%	6%	78%	0,47
bal_corr	67%	85%	6%	78%	0,12
TF-IDF	41%	84%	0%	74%	3,20
Glove	66%	87%	11%	80%	14,43
BERT	78%	89%	10%	83%	129,69

Tabela 4 - Resultados no modelo Random Forest

Legenda:

- menor que 30%
- entre 30% e 50%
- entre 50% e 80%
- entre 80% e 90%
- entre 90% e 100%

Random Forest Discussão

- O modelo, apesar de ter uma accuracy alta em todas as abordagens, não é bom, pois não consegue identificar nada bem a classe viés. Isto pode acontecer, porque cada árvore recebe só uma parte dos dados, reduzindo ainda mais o número já limitado de amostras da classe minoritária.
- O modelo foi bastante afetado pelo desbalanceamento entre classes.
- Na abordagem BERT, o tempo de execução foi de aproximadamente 130 segundos (valor mais elevado em todos os modelos). Isto pode ser porque o melhor valor encontrado para o número de árvores foi 402 o que evidencia a escassa presença da classe viés em cada árvore, uma vez que por ser uma classe muito pequena, ao ser distribuída por 402 estimadores, fica muito reduzida ou até inexistente para alguns deles.

Melhor abordagem neste modelo:

BERT

Redes Neuronais

As Redes Neuronais são modelos inspirados no funcionamento do cérebro humano, compostas por camadas de neurónios artificiais que processam e transmitem informação. Cada neurónio aplica pesos e funções de ativação às entradas, permitindo ao modelo aprender relações complexas entre as features e as classes. Os resultados obtidos em cada abordagem, com os melhores parâmetros estão representados abaixo.

Método	F1 score			Accuracy	Tempo de execução
	Citação	Facto	Viés		
nbal	64%	86%	12%	77%	6,24
bal	63%	49%	20%	45%	0,72
nbal_corr	66%	85%	5%	78%	1,24
bal_corr	67%	85%	5%	77%	0,43
TF-IDF	61%	83%	21%	74%	35,96
Glove	66%	84%	32%	76%	14,18
BERT	89%	92%	48%	88%	15,40

Tabela 5 - Resultados no modelo Redes Neuronais

Legenda:

- menor que 30%
- entre 30% e 50%
- entre 50% e 80%
- entre 80% e 90%
- entre 90% e 100%

Redes Neuronais Discussão

- Foi o modelo que obteve a accuracy mais alta (88%) na abordagem BERT.
- O segundo valor mais alto de accuracy foi de 87% na Regressão Logística usando BERT. Comparando estes dois melhores modelos, as Redes Neuronais apesar de terem 1% a menos no valor de F1-score na classe citação, têm 1% a mais tanto no valor F1-score da classe de viés como na accuracy geral.
- O Glove teve um melhor desempenho do que o TF-IDF.
- O modelo foi afetado pelo desbalanceamento de uma forma uniforme, nas diferentes abordagens para cada classe. Cada classe tem praticamente as mesmas cores (citação maioritariamente a amarelo, facto maioritariamente a verde e viés maioritariamente a vermelho), o que evidencia valores de F1-score muito parecidos em cada uma delas.

Melhor abordagem neste modelo:

BERT

Resultados do melhor modelo

- Comparando as outras métricas de recall, precision e accuracy, o modelo que consideramos ter um melhor desempenho são as **Redes Neuronais** usando a abordagem **BERT** para representação linguística.
- Como era previsível, esta abordagem foi a que produziu os melhores resultados na maioria dos modelos. Isto acontece porque esta representa cada palavra através de um vetor ajustado ao contexto em que aparece, considerando tanto palavras que aparecem antes como depois. Assim, a mesma palavra pode receber vetores diferentes consoante o seu significado na frase, ao contrário do GloVe. A frase é então representada pelo vetor médio dos vetores das suas palavras.

Relatório de classificação:

	precision	recall	f1-score	support
Citação (-1)	0.88	0.90	0.89	417
Facto (0)	0.91	0.94	0.92	1273
Viés (1)	0.59	0.40	0.48	168
accuracy			0.88	1858
macro avg	0.79	0.75	0.76	1858
weighted avg	0.87	0.88	0.87	1858

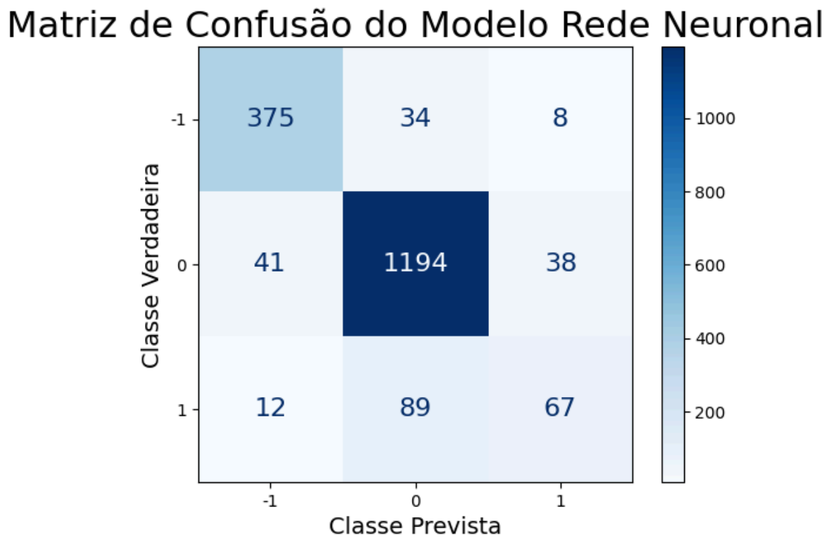

Figuras 4 e 5 - Resultados no modelo Redes Neuronais - Relatório de classificação e Matriz de confusão

Fim