Engenharia e Ciência de Dados

14 de novembro de 2025

# Meta II

# PLN

Trabalho realizado por:

Beatriz Martins - 2023210538; uc2023210538@student.uc.pt

Laura Barreto - 2023214375; uc2023214375@student.uc.pt

# Projeto 2 - PLN

## 1. Introdução

O objetivo da segunda meta é aplicar modelos de classificação para prever corretamente as classes (citação, facto ou viés) de novas amostras. O dataset tem 1391 amostras na classe citação (-1), 4242 na classe facto (0) e 558 na classe viés (1), o que evidencia o seu desbalanceamento. Desta forma, adaptámos as regras da primeira meta, convertendo-as em colunas numéricas e testando-as em quatro cenários: dados balanceados e não balanceados, com todas as colunas ou apenas as mais correlacionadas com a saída. Não foram mostradas em relatório abordagens com accuracy inferior a 50% nas nossas regras. Utilizámos também diferentes abordagens de representação textual, nomeadamente TF-IDF, GloVe e BERT e comparámos o desempenho de todas as metodologias exploradas. Na pasta "Resultados" presente no zip de entrega estão todos os resultados de todas as abordagens em cada um dos modelos.

## 2. Pré-processamento

A única etapa coincidente em todas as abordagens é a divisão dos dados, na qual dividimos os dados em treino, validação e teste (ao contrário da meta anterior), e testamos os vários parâmetros usando Optuna na etapa da validação com 400 trials e maximizando o F1-score macro. Posteriormente, obtemos as métricas finais na fase de teste treinando o modelo com os melhores parâmetros obtidos na validação. Tudo isto permitiu uma avaliação mais rigorosa do desempenho dos modelos.

Para apenas os ficheiros de regras (nbal, bal, nbal_corr e bal_corr), criámos uma coluna de tokens e adicionámos uma coluna nos dataframes para cada regra distinta. Para estes ficheiros e para a abordagem GloVe, foram também removidas as stop words.

Já para os ficheiros de regras começados por "bal", os dados de treino foram balanceados (tanto na fase de validação como na fase do teste) utilizando SMOTE e undersampling para aumentar o tamanho das classes mais pequenas e diminuir o tamanho da maior para 1000, respetivamente. Por último, para os ficheiros terminados em "corr", escolhem-se apenas as colunas mais correlacionadas com a saída (acima de 0.20 ou abaixo de -0.20) nomeadamente o número de palavras negativas exclusivas da classe viés, o número de palavras exclusivas positivas e negativas da classe citação e número de aspas (so_vies_neg, so_citação_pos, so_citacao_neg e num_aspas).

## 3. KNN

Os resultados do modelo KNN estão representados na tabela abaixo. Em geral, é possível concluir que o modelo não tem tão bom desempenho quando se baseia apenas nas colunas mais correlacionadas com a saída, devido ao valor extremamente baixo de 5% na métrica F1-score da classe viés. Isto pode acontecer porque, ao utilizar o conjunto completo de dados, é possível estimar com maior precisão as distâncias aos k vizinhos mais próximos (graças à maior quantidade de features disponíveis) e, assim, determinar com maior segurança a classe da amostra. Para além de tudo isto, o modelo foi extremamente rápido e obteve resultados bastante satisfatórios. Verificámos que as nossas regras parecem ter tido melhor desempenho do que o TF-IDF e o GloVe. O modelo BERT foi o que visivelmente obteve melhores resultados em todas as métricas.

| **Método** | **F1 score** | | | **Accuracy** | **Tempo de execução (s)** |
|---|---|---|---|---|---|
| | Citação | Facto | Viés | | |
| nbal | 59% | 84% | 11% | 75% | 0,00 |
| bal | 60% | 61% | 20% | 53% | 0,00 |
| nbal_corr | 66% | 85% | 5% | 77% | 0,00 |
| TF-IDF | 47% | 77% | 12% | 66% | 0,00 |
| GloVe | 29% | 85% | 27% | 75% | 0,00 |
| BERT | 80% | 89% | 31% | 83% | 0,01 |

**Legenda:** → **menor que 30%** → **entre 30% e 50%** → **entre 50% e 80%** → **entre 80% e 90%** → **entre 90% e 100%**

**Tabela 1 -** Resultados do modelo KNN em todas as abordagens

## 4. Regressão Logística

Os resultados do modelo Regressão Logística estão representados na tabela abaixo. Neste modelo, verificámos que a abordagem BERT obteve resultados bastante elevados com 87% de accuracy, F1-score igual a 90% na classe citação e acima de 90% na classe facto. Para além disso, quase atingiu os 50% na classe viés, a mais difícil

de classificar. A Regressão Logística tem um melhor desempenho comparativamente ao KNN em todas as métricas exceto na classe viés (nas abordagens TF-IDF e Glove). Assim, a performance geral do modelo melhorou, mas à custa de classificarmos pior a classe minoritária. Este modelo demorou ligeiramente mais tempo a ser treinado do que o KNN, especialmente na abordagem do BERT que durou aproximadamente 7 segundos.

| **Método** | **F1 score** | | | **Accuracy** | **Tempo de execução (s)** |
|---|---|---|---|---|---|
| | Citação | Facto | Viés | | |
| nbal | 57% | 84% | 11% | 75% | 0,19 |
| nbal_corr | 40% | 82% | 5% | 71% | 0,01 |
| bal_corr | 67% | 85% | 5% | 77% | 0,00 |
| TF-IDF | 58% | 84% | 10% | 75% | 0,21 |
| GloVe | 67% | 87% | 25% | 79% | 0,09 |
| BERT | 90% | 92% | 47% | 87% | 6,93 |

**Legenda:** → **menor que 30%** → **entre 30% e 50%** → **entre 50% e 80%** → **entre 80% e 90%** → **entre 90% e 100%**

**Tabela 2 -** Resultados do modelo Regressão Logística em todas as abordagens

## 5. Random Forest

Os resultados do modelo Random Forest estão representados na tabela abaixo. Verificámos que este modelo, apesar de ter uma accuracy alta em todas as abordagens, não é um bom modelo, pois não consegue identificar nada bem a classe viés. Isto pode acontecer, porque cada árvore recebe só uma parte dos dados, reduzindo ainda mais o número já limitado de amostras da classe minoritária. Assim, é possível que algumas árvores não cheguem nem a ver qualquer exemplo da classe viés, tornando mais difícil o seu reconhecimento. O modelo foi bastante afetado pelo desbalanceamento entre classes. Na abordagem BERT, vemos um tempo de execução de aproximadamente 130 segundos (valor mais elevado em todos os modelos). Isto pode estar relacionado com o facto de o melhor valor encontrado para o número de árvores ter sido 402, que é o segundo valor mais elevado entre todas as abordagens para este modelo (ficando apenas atrás da abordagem nbal_corr, onde o melhor valor foi com 458 estimators). Tudo isto evidencia a escassa presença da classe viés nas árvores, uma vez que por ser muito pequena, ao ser distribuída por 402 estimadores, fica ainda mais reduzida ou até inexistente para alguns deles.

| **Método** | **F1 score** | | | **Accuracy** | **Tempo de execução (s)** |
|---|---|---|---|---|---|
| | Citação | Facto | Viés | | |
| nbal | 66% | 85% | 11% | 78% | 0,16 |
| nbal_corr | 67% | 85% | 6% | 78% | 0,47 |
| bal_corr | 67% | 85% | 6% | 78% | 0,12 |
| TF-IDF | 41% | 84% | 0% | 73% | 3,20 |
| GloVe | 66% | 87% | 11% | 80% | 14,43 |
| BERT | 78% | 89% | 10% | 83% | 129,69 |

**Legenda:** → **menor que 30%** → **entre 30% e 50%** → **entre 50% e 80%** → **entre 80% e 90%** → **entre 90% e 100%**

**Tabela 3 -** Resultados do modelo Random Forest em todas as abordagens

## 6. Redes Neuronais

Os resultados do modelo **Redes Neuronais** estão representados na tabela abaixo. Este foi o modelo que obteve a accuracy mais alta (88%) na abordagem BERT. O segundo valor mais alto de accuracy foi de 87% na **Regressão Logística** usando BERT. Comparando estes dois melhores modelos, as Redes Neuronais apesar de terem 1% a menos no valor de F1-score na classe citação, têm 1% a mais tanto no valor F1-score da classe de viés como na accuracy geral. Para além disso, podemos observar também que o Glove teve um melhor desempenho do que o TF-IDF. Por fim, este modelo foi influenciado pelo desbalanceamento de forma semelhante nas diferentes abordagens para cada classe, como se observa na Tabela 4. As cores atribuídas a cada classe mantêm-se quase inalteradas (citação sobretudo a amarelo, facto a verde e viés a vermelho), o que reflete valores de F1-score muito próximos entre si.

| Método | F1 score | | | Accuracy | Tempo de execução (s) |
|---|---|---|---|---|---|
| | Citação | Facto | Viés | | |
| nbal | 64% | 86% | 12% | 77% | 6,24 |
| nbal_corr | 66% | 85% | 5% | 78% | 1,24 |
| bal_corr | 67% | 85% | 5% | 77% | 0,43 |
| TF-IDF | 61% | 83% | 21% | 74% | 35,96 |
| GloVe | 66% | 84% | 32% | 76% | 14,18 |
| BERT | 89% | 92% | 48% | 88% | 15,40 |

**Legenda:** → **menor que 30%** → **entre 30% e 50%** → **entre 50% e 80%** → **entre 80% e 90%** → **entre 90% e 100%**

**Tabela 4 -** Resultados do modelo Redes Neuronais em todas as abordagens

## 7. Discussão

Analisando todos os resultados presentes na pasta de resultados acreditamos que tenha sido a rede neuronal na abordagem do BERT que teve melhor desempenho. Com este modelo em 417 amostras da classe citação detetámos 375, em 1273 amostras da classe facto detetámos 1194 e em 168 amostras da classe viés detetámos 67. É possível observar que temos valores bastante elevados a nível da precision e recall nas duas primeiras classes e que, na classe viés obtivemos uma precision de 59% e um recall comparativamente menor de 40%.

```
Relatório de classificação:
              precision    recall  f1-score   support

Citação (-1)       0.88      0.90      0.89       417
   Facto (0)       0.91      0.94      0.92      1273
    Viés (1)       0.59      0.40      0.48       168

    accuracy                           0.88      1858
   macro avg       0.79      0.75      0.76      1858
weighted avg       0.87      0.88      0.87      1858
```

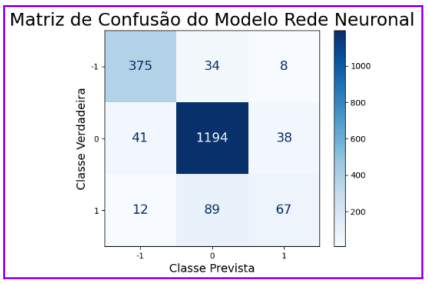


**Figura 1 -** Resultados do modelo Redes Neuronais usando o BERT

Em geral, é possível perceber que os modelos têm melhor desempenho quando é utilizado BERT. Isto deve-se ao facto de esta abordagem ter em conta o contexto em que as palavras surgem, podendo atribuir vetores diferentes à mesma palavra consoante o contexto em que está inserida (ao contrário do GloVe), o que acaba por ser benéfico para este dataset. Assim, uma representação contextualizada (usando o vetor médio dos vetores das palavras na frase) permite capturar nuances semânticas que métodos como o TF-IDF e GloVe não conseguem representar de forma adequada.

A classe viés continua a ser a mais difícil de distinguir sobretudo por ser extremamente parecida com a classe citação e por ter um menor número de exemplos. Mesmo com os dados balanceados esta classe teve valores consistentemente baixos de F1-score (o máximo alcançado foi 48% neste modelo de Redes Neuronais). Este resultado sugere que as frases da classe viés não seguem o mesmo padrão, o que leva a que os modelos tenham dificuldade em criar fronteiras de decisão claras e que se ajustem bem a esta classe.

Mesmo recorrendo às abordagens de representação textual TF-IDF, GloVe e BERT, o desempenho nesta classe manteve-se insatisfatório. Assim, o facto de obter apenas 48% de F1-score, pode significar que uma parte significativa das amostras desta classe não partilha características discriminativas evidentes, levando a erros recorrentes de classificação e consequentemente a métricas mais baixas. Isto também prova que a qualidade do dataset não é a melhor, pois tem muitas frases viés que, ao serem lidas, seriam classificadas de outra forma.

## 8. Conclusão

Concluindo, nesta segunda meta foi-nos possível não só aprender os tipos de representação textual (TF-IDF, GloVe e BERT), como também reavivar os conhecimentos acerca de todos os modelos existentes e dos testes de parâmetros usando Optuna, elementos que foram muito usados em Aprendizagem Computacional.