Engenharia e Ciência de Dados

12 de dezembro de 2025

Meta III
PLN

Trabalho realizado por:

Beatriz Martins - 2023210538; uc2023210538@student.uc.pt
Laura Barreto - 2023214375; uc2023214375@student.uc.pt

Introdução

O dataset escolhido para este trabalho foi o “factnews_dataset.csv”, composto por 6191 linhas e 7 colunas: *file*, *id_sente*, *id_article*, *domain*, *year*, *sentences* e *classe*. As classes possíveis para as frases são: citação (-1), facto (0) ou viés (1), existindo 1391 citações, 4242 factos e 558 frases com viés, o que revela um forte desbalanceamento, especialmente na classe viés.

Na primeira meta, o objetivo foi desenvolver um conjunto de regras linguísticas capazes de classificar as frases nas três categorias. Criámos três funções para identificar citação, facto ou viés, cada uma verificando um conjunto de condições e contando quantas são satisfeitas. No fim, a frase é atribuída à categoria com o maior número de condições cumpridas.

Na segunda meta, procurou-se aplicar modelos de classificação para prever essas mesmas classes, convertendo as regras iniciais em variáveis numéricas e testando diferentes cenários: dados balanceados e não balanceados, e utilização de todas as colunas ou apenas das mais correlacionadas. Apenas métodos com *accuracy* superior a 50% foram incluídos no relatório. Foram ainda exploradas várias representações textuais como TF-IDF, GloVe e BERT e comparado o seu desempenho nos diferentes modelos. Todos os resultados encontram-se na pasta “Resultados” incluída no ficheiro de entrega.

Na terceira meta, o foco foi a utilização de Large Language Models (LLMs), nomeadamente o modelo dado em aula Ollama3.2:3b, para realizar a mesma tarefa de classificação. Para cada frase de teste, foram efetuadas três tentativas independentes, de modo a aumentar a robustez da classificação, escolhendo a classe com maior quantidade de votos das três tentativas.

Meta 1 - PLN

1. Pré-processamento

Antes de aplicar as regras de classificação desenvolvidas, confirmámos que o dataset não continha linhas duplicadas nem valores nulos. Em seguida, analisámos as correlações entre as variáveis de entrada (exceto *file* e *sentences*) e a variável alvo, verificando que eram muito fracas (entre -0.1 e 0.1). Os dados foram depois divididos em treino e teste com *stratify*, garantindo que a proporção das classes se mantinha em ambos os conjuntos, resultando em 2969 citações, 974 factos e 390 frases com viés no treino. Para preparar melhor a informação textual, acrescentámos ao conjunto de treino três novas colunas: “tokens” (palavras sem stopwords), “doc” (frases convertidas em objetos spaCy) e “bigrams” (pares de palavras consecutivas extraídos das frases).

2. Regras comuns a todas as classes

Optámos por usar os adjetivos, advérbios, palavras e verbos mais frequentes de cada classe, pois os restantes elementos testados (entidades, bigramas e funções sintáticas) não permitiam distinguir tão bem as 3 as classes. Consideramos apenas as 5 mais frequentes, por ser o número que nos deu melhores resultados. Portanto, se a frase contiver algum dos 5 verbos mais frequentes de uma classe, ou algum dos sinónimos dos lemas desses verbos, aumentamos mais uma condição verificada dessa classe. O mesmo acontece caso a frase contenha os 5 adjetivos, advérbios ou palavras mais frequentes.

```
Verbos mais frequentes por classe:
Classe 0: [('ter', 211), ('dizer', 174), ('fazer', 163), ('poder', 96), ('afirmar', 95)]
Classe 1: [('ter', 34), ('fazer', 27), ('poder', 19), ('dever', 15), ('dar', 14)]
Classe -1: [('dizer', 185), ('ter', 142), ('afirmar', 94), ('fazer', 54), ('poder', 49)]
Adjetivos mais frequentes por classe:
Classe 0: [('primeiro', 89), ('segundo', 57), ('maior', 48), ('nova', 47), ('eleitoral', 34)]
Classe 1: [('segundo', 12), ('primeiro', 9), ('eleitoral', 8), ('segunda', 7), ('terceiro', 7)]
Classe -1: [('eleitoral', 17), ('possível', 16), ('melhor', 14), ('primeiro', 12), ('"', 11)]
Advérbios mais frequentes por classe:
Classe 0: [('não', 294), ('mais', 189), ('também', 184), ('já', 110), ('ainda', 97)]
Classe 1: [('não', 60), ('mais', 43), ('também', 29), ('já', 18), ('muito', 12)]
Classe -1: [('não', 236), ('mais', 62), ('sempre', 30), ('muito', 27), ('já', 27)]
Palavras mais frequentes por classe:
Classe 0: [('presidente', 252), ('lula', 223), ('segundo', 199), ('bolsonaro', 197), ('sobre', 143)]
Classe 1: [('bolsonaro', 39), ('lula', 37), ('presidente', 33), ('governo', 26), ('sobre', 25)]
Classe -1: [('disse', 129), ('afirmou', 71), ('lula', 63), ('presidente', 53), ('sobre', 48)]
```

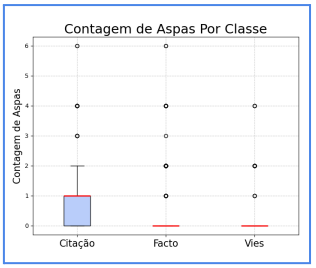

Figura 1 e 2 - Elementos mais frequentes nas 3 classes e Contagem de Aspas por Classe

Pela figura 2, as citações apresentam mais aspas do que os factos e os viés. O que constitui um bom indicador para distinguir citações, já que factos e viés raramente contêm aspas. Assim, definimos a seguinte regra: se a frase contiver uma aspa, incrementa-se a contagem da classe **Citação**. Caso não tenha, incrementa-se a contagem das classes **Facto** e **Viés**.

3. Regras adicionais na classe Viés

Testámos a polaridade das frases para verificar se a classe viés apresentava mais termos negativos, usando o dataset “Sentilex.csv” (com 82347 palavras e a sua polaridade). Contudo, concluímos que todas as classes continham mais frases negativas, conforme ilustrado na figura 3.

```
CLASSE:  -1 ;Negativas:  684 ; Neutras:  98 Positivas:  192
CLASSE:  0 ;Negativas:  2101 ; Neutras:  335 Positivas:  533
CLASSE:  1 ;Negativas:  259 ; Neutras:  48 Positivas:  83
```

Figura 3 - Distribuição do número de frases negativas, neutras e positivas de cada classe

Em alternativa, analisámos a frequência de palavras negativas nas frases das três classes (figura 4) e concluímos que o viés tende a apresentar uma frequência ligeiramente mais elevada, embora, de forma geral, palavras negativas apareçam muito pouco em todas as classes. Isto sugere que o dataset SentiLex contém poucas palavras que apareçam no nosso dataset FactNews, como “presidente” e “Lula”, o que confirmámos ser verdade. Para contornar esta limitação, adicionámos uma regra na função detetar_vies: se a frequência de palavras negativas ultrapassar 0,075 (valor máximo da classe facto sem considerar outliers) incrementa-se 1 às condições da classe viés, pois acima desse limiar apenas ocorrem exemplos dessa classe.

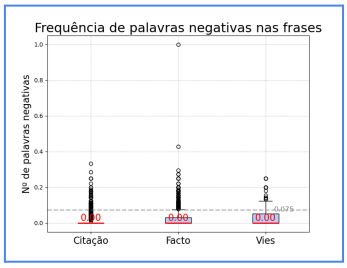

Figura 4 - Distribuição da frequência de palavras negativas nas frases de cada classe

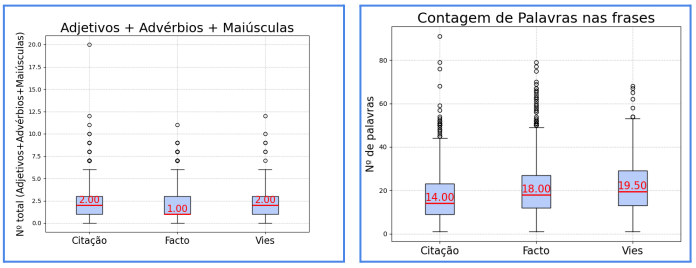

Figuras 5 e 6 - Distribuição do número de adjetivos, advérbios e maiúsculas aspa e do número de palavras nas frases de cada classe

Adotámos ainda outra estratégia: criámos listas de palavras negativas, positivas e neutras para todas as classes, removendo da classe viés aquelas que também apareciam nas outras classes, obtendo listas exclusivas de palavras representativas desta classe. Em seguida, acrescentámos três condições, que verificam se a frase contém alguma das palavras exclusivas das listas negativa, positiva e neutra de viés, e se acontecer adicionamos uma condição verificada. Após verificar os boxplots da figura 5, obtivemos, então outra regra na classe viés: se o número de adjetivos, advérbios e de letras maiúsculas após uma aspa for maior ou igual do que 4 e a contagem de palavras nas frases for superior a 18, então verificamos mais uma condição na classe viés (estes valores foram os que nos pareceram obter melhores resultados mais à frente). Decidimos testar o número de palavras, advérbios, adjetivos e maiúsculas (figuras 5 e 6), porque achámos que as classes facto e citação teriam valores menores (no caso do facto por ser geralmente mais objetivo) e a classe viés teria valores mais altos, já que é constituída por frases tendenciosas ou opinativas.

4. Resultados e Discussão

Usando as regras descritas anteriormente, e atribuindo a cada uma delas o mesmo peso de 1, caso a condição seja verificada, obtemos a seguinte matriz de confusão e classification report.

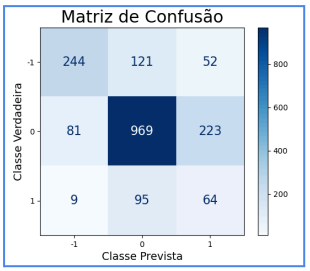

	precision	recall	f1-score	support
-1	0.73	0.59	0.65	417
0	0.82	0.76	0.79	1273
1	0.19	0.38	0.25	168
accuracy			0.69	1858
macro avg	0.58	0.58	0.56	1858
weighted avg	0.74	0.69	0.71	1858

Figura 6 - Resultados das métricas atribuindo peso 1 a todas as regras

Decidimos fazer um grid search manual para encontrar a melhor combinação de pesos das regras e maximizar a F1-macro das três classes. Testámos todas as combinações possíveis usando os valores 0.5, 1 e 2, mantendo o peso das aspas fixo em 2 por ser uma regra muito forte. Os pesos das palavras negativas, neutras e positivas exclusivas da classe viés ficaram sempre em 0.5, já que aparecem pouco nessa classe.

```
Melhor combinação: {'peso_verbos': 1, 'peso_adverbios': 0.5, 'peso_adjetivos': 2, 'peso_palavras': 1, 'peso_freq_neg': 0.5, 'peso_comb_vies': 0.5}
Melhor média de F1: 0.5718903815028734
```

Figura 7 - Pesos atribuídos às regras pelo grid search

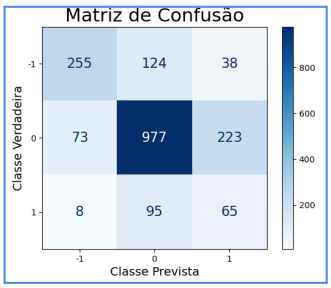

	precision	recall	f1-score	support
-1	0.76	0.61	0.68	417
0	0.82	0.77	0.79	1273
1	0.20	0.39	0.26	168
accuracy			0.70	1858
macro avg	0.59	0.59	0.58	1858
weighted avg	0.75	0.70	0.72	1858

Figura 8 - Resultados das métricas atribuindo os pesos provenientes do grid search

Houve pequenas melhorias com o ajuste dos pesos: a F1-score subiu 3% na classe citação, 1% na classe viés e a accuracy geral aumentou 1%. As regras que mais ajudam a diferenciar as classes são os adjetivos e os verbos característicos de cada uma. As regras mais fracas (peso 0.5) são os advérbios frequentes, as palavras negativas associadas ao viés e a combinação de advérbios, adjetivos, maiúsculas após aspas e comprimento da frase. Tal como se vê na figura 8, as classes 0 e -1 são classificadas muito melhor do que a classe 1. Isto acontece porque a classe viés tem menos exemplos e exige regras mais específicas. Além disso, 223 frases de viés são equivocadamente classificadas como factos. Mesmo assim, o desempenho global é razoável: foram detetadas 255 citações de 417, 977 factos de 1273 e 65 viés de 168. Nas classes citação e facto, a precision supera o recall, significando que há mais falsos negativos do que falsos positivos.

Meta 2 - PLN

1. Pré-processamento

A única etapa comum a todas as abordagens foi a divisão dos dados em treino, validação e teste, ao contrário da meta anterior. Os parâmetros dos modelos foram ajustados com Optuna (400 trials), maximizando o F1-score macro na validação. Depois, com os melhores parâmetros, treinou-se novamente o modelo e obtiveram-se as métricas finais na fase de teste, garantindo uma avaliação mais rigorosa. Nos ficheiros de regras (nbal, bal, nbal_corr e bal_corr), criou-se uma coluna de tokens e uma coluna por cada regra distinta. Para estes ficheiros e também para a abordagem GloVe, removeram-se stop words. Nos ficheiros de regras iniciados por "bal", os dados de treino foram balanceados com SMOTE (aumentar classes minoritárias) e undersampling (reduzir a classe maior para 1000), tanto na validação como no teste. Nos ficheiros de regras terminados em "corr", selecionaram-se apenas as features mais correlacionadas com a saída (|corr| > 0.20): so_vies_neg, so_citação_pos, so_citacao_neg e num_aspas.

2. KNN

Os resultados do modelo KNN estão representados na tabela abaixo. Em geral, é possível concluir que o modelo não tem tão bom desempenho quando se baseia apenas nas colunas mais correlacionadas com a saída, devido ao valor extremamente baixo de 5% na métrica F1-score da classe viés. Isto pode acontecer porque, ao utilizar o conjunto completo de dados, é possível estimar com maior precisão as distâncias aos k vizinhos mais próximos (graças à maior quantidade de features disponíveis) e, assim, determinar com maior segurança a classe da amostra. Para além de tudo isto, o modelo foi extremamente rápido e obteve resultados bastante satisfatórios. Verificámos que as nossas regras parecem ter tido melhor desempenho do que o TF-IDF e o GloVe. O modelo BERT foi o que visivelmente obteve melhores resultados em todas as métricas.

Método	F1 score			Accuracy	Tempo de execução (s)
	Citação	Facto	Viés		
nbal	59%	84%	11%	75%	0,00
bal	60%	61%	20%	53%	0,00
nbal_corr	66%	85%	5%	77%	0,00
TF-IDF	47%	77%	12%	66%	0,00
GloVe	29%	85%	27%	75%	0,00
BERT	80%	89%	31%	83%	0,01

Legenda: → **menor que 30%** → **entre 30% e 50%** → **entre 50% e 80%** → **entre 80% e 90%** → **entre 90% e 100%**

Tabela 1 - Resultados do modelo KNN em todas as abordagens

3. Regressão Logística

Os resultados do modelo Regressão Logística estão representados na tabela abaixo. Neste modelo, verificámos que a abordagem BERT obteve resultados bastante elevados com 87% de accuracy, F1-score igual a 90% na classe citação e acima de 90% na classe facto. Para além disso, quase atingiu os 50% na classe viés, a mais difícil de classificar. A Regressão Logística tem um melhor desempenho comparativamente ao KNN em todas as métricas exceto na classe viés (nas abordagens TF-IDF e Glove). Assim, a performance geral do modelo melhorou, mas à custa de classificarmos pior a classe minoritária. Este modelo demorou ligeiramente mais tempo a ser treinado do que o KNN, especialmente na abordagem do BERT que durou aproximadamente 7 segundos.

Método	F1 score			Accuracy	Tempo de execução (s)
	Citação	Facto	Viés		
nbal	57%	84%	11%	75%	0,19
nbal_corr	40%	82%	5%	71%	0,01
bal_corr	67%	85%	5%	77%	0,00
TF-IDF	58%	84%	10%	75%	0,21
GloVe	67%	87%	25%	79%	0,09
BERT	90%	92%	47%	87%	6,93

Legenda: → **menor que 30%** → **entre 30% e 50%** → **entre 50% e 80%** → **entre 80% e 90%** → **entre 90% e 100%**

Tabela 2 - Resultados do modelo Regressão Logística em todas as abordagens

4. Redes Neuronais

Os resultados do modelo **Redes Neuronais** estão representados na tabela abaixo. Este foi o modelo que obteve a accuracy mais alta (88%) na abordagem BERT. O segundo valor mais alto de accuracy foi de 87% na **Regressão Logística** usando BERT. Comparando estes dois melhores modelos, as Redes Neuronais apesar de terem 1% a menos no valor de F1-score na classe citação, têm 1% a mais tanto no valor F1-score da classe de viés como na accuracy geral. Para além disso, podemos observar também que o Glove teve um melhor desempenho do que o TF-IDF. Por fim, este modelo foi influenciado pelo desbalanceamento de forma semelhante nas diferentes abordagens para cada classe, como se observa na Tabela 4. As

cores atribuídas a cada classe mantêm-se quase inalteradas (citação sobretudo a amarelo, facto a verde e viés a vermelho), o que reflete valores de F1-score muito próximos entre si.

Método	F1 score			Accuracy	Tempo de execução (s)
	Citação	Facto	Viés		
nbal	64%	86%	12%	77%	6,24
nbal_corr	66%	85%	5%	78%	1,24
bal_corr	67%	85%	5%	77%	0,43
TF-IDF	61%	83%	21%	74%	35,96
GloVe	66%	84%	32%	76%	14,18
BERT	89%	92%	48%	88%	15,40

Legenda: → **menor que 30%** → **entre 30% e 50%** → **entre 50% e 80%** → **entre 80% e 90%** → **entre 90% e 100%**

Tabela 4 - Resultados do modelo Redes Neuronais em todas as abordagens

5. Discussão

Analisando todos os resultados acreditamos que tenha sido a rede neuronal na abordagem do BERT que teve melhor desempenho. Com este modelo em 417 amostras de Citação detetámos 375, em 1273 amostras de Facto detetámos 1194, e em 168 amostras de Viés detetámos 67. Obtemos valores bastante elevados de precision e recall nas duas primeiras classes e na classe viés obtivemos uma precision de 59% e um recall comparativamente menor de 40%.

```
Relatório de classificação:
              precision    recall  f1-score   support

Citação (-1)       0.88      0.90      0.89       417
   Facto (0)       0.91      0.94      0.92      1273
    Viés (1)       0.59      0.40      0.48       168

    accuracy                           0.88      1858
   macro avg       0.79      0.75      0.76      1858
weighted avg       0.87      0.88      0.87      1858
```

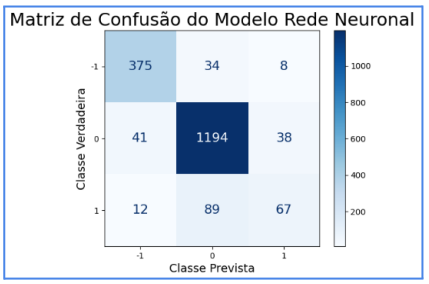

Figura 9 - Resultados do modelo Redes Neuronais usando o BERT

É possível perceber que os modelos têm melhor desempenho usando o BERT. Isto deve-se ao facto de esta abordagem ter em conta o contexto das palavras, podendo atribuir vetores diferentes à mesma palavra consoante o contexto em que está inserida (ao contrário do GloVe). Assim, uma representação contextualizada (usando o vetor médio dos vetores das palavras na frase) permite capturar nuances semânticas que o TF-IDF e GloVe não conseguem representar de forma adequada. A classe viés continua a ser a mais difícil de distinguir sobretudo por ser extremamente parecida com a classe citação e por ter menos amostras. Mesmo com os dados balanceados esta classe teve valores consistentemente baixos de F1-score (o máximo alcançado foi 48% neste modelo de Redes Neuronais). Isto sugere que as frases da classe viés não seguem o mesmo padrão, dificultando a criação de fronteiras de decisão claras por parte dos modelos. Mesmo recorrendo às abordagens do TF-IDF, GloVe e BERT, o desempenho nesta classe manteve-se insatisfatório. Assim, o facto de obter apenas 48% de F1-score, pode significar que uma parte significativa das amostras desta classe não partilha características discriminativas evidentes, levando a erros de classificação e a métricas mais baixas. Isto também prova que a qualidade do dataset não é a melhor, pois tem muitas frases viés que, ao serem lidas, seriam classificadas de outra forma.

Meta 3 - PLN

1. Introdução

Para este trabalho, foi usado o modelo trabalhado em aula, **llama3.2:3b,** que é um modelo de linguagem aberto, baseado em Transformers, com cerca de 3B de parâmetros, leve, rápido e adequado a Prompt Engineering, permitindo classificar diretamente as frases como citação, facto e viés, sem necessidade de treino adicional. Foi utilizada uma temperatura baixa de 0.1 para que o modelo seja assertivo e não criativo nas suas respostas de classificação.

Durante este processo, foi ainda necessário implementar um pós-processamento para identificar corretamente a presença das classes (“-1”, “0” ou “1”) nas respostas textuais do modelo, assegurando que variações de formatação, como espaços antes ou depois de um número não originavam classificações incorretas. Verificou-se também que 36 frases do conjunto de teste continham conteúdos sensíveis (nomeadamente relacionados com suicídio, pedofilia e assassinato), o que levou o modelo Ollama a recusar a sua classificação por motivos éticos, considerando-as inválidas. Tendo o conjunto de teste 1858 frases, estas 36 foram retiradas da avaliação final, permitindo a comparação entre as três abordagens (Zero-shot, Few-shot e Chain-of-Thoughts) e respeitando as limitações éticas do modelo utilizado.

```
Número de Frases Inválidas: 36
Frases Inválidas que o LLM não pode classificar:
180: "Você acha que uma mãe que tem quatro filhos aos 20 anos de idade, que não tem nem o primário completo tem condições de dar um futuro familiar a uma criança ?
366: Ex-policial ataca creche na Tailândia e mata ao menos 24 crianças.
487: Fechar o olho e não acordar mais.
973: "Como você pode sair com uma mulher na menopausa?
799: Em entrevista ao Flow Podcast, Lula afirmou que Bolsonaro se "comporta como se fosse um pedófilo".
952: Depois, o homem voltou para sua casa, matou a mulher e o filho a tiros e se suicidou, ainda de acordo com policiais que investigam o caso.
989: Após a tragédia, os dois adolescentes cometeram suicídio.
1286: O ex-policial então forçou a entrada em uma sala trancada onde as crianças dormiam, disse Boonsom, e as esfaqueou.
1418: Pelo amor de Deus.
```

Figura 10 - Exemplos de frases inválidas, não classificadas pelo LLM

2. Zero-shot

Experimentámos alguns exemplos iniciais de prompt, mas não foram eficientes porque o modelo alucinava ou não fornecia a resposta no formato esperado, o que impossibilitava a leitura da classe corretamente. Por exemplo, às vezes retornava “-1” (Citação), mas representava um 1 (Viés) com um traço atrás, ou dava explicações mas não dizia o número da classe. Por exemplo: quando na prompt da figura 11, lhe pedíamos “Responda Exatamente com -1, 0 ou 1.” com o ponto final, ele por vezes respondia o número com o ponto de seguida, o que gerou, inicialmente, algumas dificuldades a obter a classe na resposta. Para além disso, quando lhe fazíamos esse pedido, por vezes, o LLM colocava “A classe da frase é:...” ou “Classificação:...” o que dificultou o pós-processamento nas primeiras tentativas. Deste modo, no pós-processamento, verificámos se a resposta do LLM continha um “1”, “0” ou “-1”, assegurando que distinguíamos corretamente entre estas ocorrências. Para tal, tivemos especial atenção a diferentes formas de representação dos números, por exemplo, “ 1 ” com espaços, de modo a evitar confusões com “-1”, que também inclui o dígito “1”. No geral, não tivemos muitos problemas nesta abordagem porque, com estes prompts otimizados, as respostas do LLM eram praticamente todas só com o número correspondente da classe da frase. Dito isto, testámos dois prompts nas 51 primeiras amostras de teste, para poder escolher a que desse melhor resultado, para posteriormente ser usada no conjunto de teste total.

```
prompt = (
'Classifique a frase abaixo em APENAS UMA das seguintes classes:\n'
'- "-1" para CITAÇÃO\n'
'- "0" para FACTO\n'
'- "1" para VIÉS\n\n'
'Responda EXATAMENTE com -1, 0 ou 1\n'
'Frase: '
)
```

```
Relatório de classificação:
              precision    recall  f1-score   support

Citação (-1)       0.33      0.12      0.17        17
   Facto (0)       0.50      0.03      0.06        31
    Viés (1)       0.05      0.67      0.09         3

    accuracy                           0.10        51
   macro avg       0.29      0.27      0.11        51
weighted avg       0.42      0.10      0.10        51
```

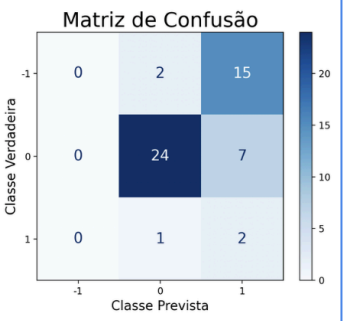

Figura 11 - Prompt usado sem explicação das classes, Matriz de Confusão e Classification Report

Isto pode mostrar que a maioria das frases do dataset, sem nenhum contexto, podem parecer enviesadas ou ter um tom de julgamento. Um exemplo de frase que segue o anteriormente dito é "Esse projeto é uma forma de criminalização das pesquisas e a gente precisa ter um entendimento de que as pesquisas não são ciências exatas, inclusive elas são formas de trazer informações e a partir daquelas informações pode-se mudar o cenário das intenções de voto" que até é classificada como viés nas três tentativas, no entanto trata-se de uma citação.

```
prompt = (
'Classifique a frase abaixo em APENAS UMA das seguintes classes:\n'
'-1 (CITAÇÃO): Declarações diretas, geralmente com pelo menos uma aspa.'
'0 (FACTO): Informação apresentada de forma imparcial, centrada em factos objetivos.'
'1 (VIÉS): Informação tendenciosa, apresentando um ponto de vista parcial ou influenciado.'
'Responda EXATAMENTE com -1, 0 ou 1\n'
'Frase: '
)
```

```
Relatório de classificação:
              precision    recall  f1-score   support

Citação (-1)       0.41      0.88      0.56        17
   Facto (0)       0.92      0.35      0.51        31
    Viés (1)       0.00      0.00      0.00         3

    accuracy                           0.51        51
   macro avg       0.44      0.41      0.36        51
weighted avg       0.69      0.51      0.50        51
```

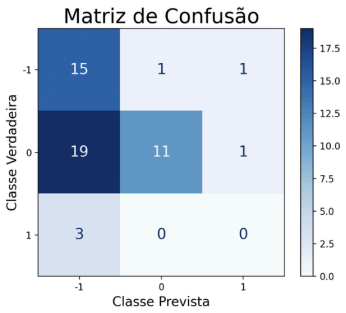

Figura 12 - Prompt usado com explicação das classes, Matriz de Confusão e Classification Report

O **segundo prompt** (figura 12)**,** que fornece uma pequena explicação de cada classe, teve uma accuracy mais alta de 51%. Já o prompt que não dá nenhuma explicação apenas alcançou 10% nesta métrica. Mesmo que a classe viés esteja a ser mal classificada no segundo prompt (tendo 0% em todas as métricas), os resultados desta abordagem são significativamente melhores do que no **primeiro prompt** (figura 11), em que os resultados da métrica F1-score foram bastante baixos para todas as classes (17% para a classe citação, 6% para facto e 9% para viés). Desta forma, optámos pela segunda abordagem e abaixo estão os seus resultados no conjunto total de teste.

```
Relatório de classificação:
              precision    recall  f1-score   support

Citação (-1)       0.26      0.93      0.41       398
   Facto (0)       0.90      0.27      0.41      1258
    Viés (1)       0.15      0.04      0.07       166

    accuracy                           0.39      1822
   macro avg       0.44      0.41      0.30      1822
weighted avg       0.69      0.39      0.38      1822
```

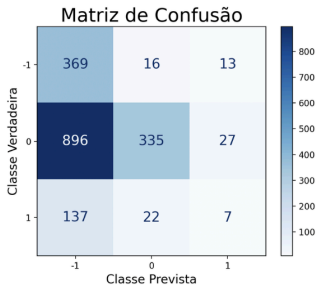

Figura 13 - Resultados no teste total, Matriz de Confusão e Classification Report

Podemos perceber que no conjunto de teste obtivémos uma accuracy (39%) um pouco mais baixa do que nas primeiras 51 amostras (51%), mas já temos valores não nulos de F1-score da classe viés com 7%, continuando a ser um valor extremamente baixo. Percebemos que a classe da Citação tem imensos falsos positivos que correspondiam à classe Facto, isto pode estar relacionado com a descrição de citação que pode ser demasiado generalizável (como dizemos que tem pelo menos uma aspa) ou com o facto de o nosso dataset ter algumas frases que se podem confundir e talvez precisasse de uma descrição das classes mais aprofundada. No entanto, optámos por estas descrições mais simples e baseadas no artigo presente na página do nosso dataset, que nos pareciam ser as mais acertadas. Por fim, o nosso dataset apresenta frases que aparentam estar mal classificadas, como já mencionado em metas anteriores. Assim, mesmo com o uso de prompt engineering e com explicações ou contextos mais específicos para cada classe, é compreensível que os resultados não sejam satisfatórios, especialmente porque, por se tratar da abordagem zero-shot, ainda não foi fornecido nenhum exemplo de treino ao modelo.

3. Few-shot

Inicialmente, experimentámos alguns prompts só com as 51 primeiras amostras de teste, de forma a escolher o melhor prompt possível para ser, posteriormente, usado para o conjunto de teste inteiro. Para escolher os exemplos de treino, decidimos usar seis exemplos de cada classe. Usámos as três funções da primeira meta com as regras linguísticas, que já retornavam o número de condições verificadas de uma frase em cada classe, e ordenamos as frases decrescentemente pelo score, selecionando assim as 10 frases mais representativas de cada classe. No entanto, algumas frases pareciam extremamente mal estruturadas, como é o exemplo da frase “O candidato Lula, que não veio, por estar com salto alto ou achar que já ganhou..." que é classificada como citação sendo que parece ser enviesada. Para além disso, descartámos duas frases idênticas presentes em ambas as classes viés e facto: “Os dados verdadeiros da pesquisa, também apresentados pelo Jornal Nacional, mostram que Lula tem 53% das intenções de voto no segundo turno, enquanto Bolsonaro tem 36%.”. Desta forma, das 10 frases mais representativas de cada classe escolhemos apenas as seis que nos pareciam mais estruturadas e mais de acordo com a classe a que foram atribuídas. No caso da **citação**, obtivemos frases com a presença de expressões como “disse o presidente do partido.”, “afirmou o ex-presidente.” ou “disse.” e ainda de aspas e de discurso direto. Já nos **factos**, é bastante frequente apresentarem dados numéricos, como por exemplo: “11,5 mil habitantes” ou mesmo percentagens (“10.45% do total de óbitos”). Para além disso, também têm expressões como “segundo a plataforma Worldometers” e a presença de datas e horas associadas ao facto referido como por exemplo: “Em 2022 (...)” e “Também nesta sexta, às 19h (...)”. Na classe **viés**, as frases são mais pejorativas e têm um caráter de julgamento, sendo baseadas na opinião de alguém e bastante subjetivas, como por exemplo: “A comissão jurídica não tem nenhum efeito jurídico…”, “Sem citar nominalmente o adversário…”, “Desde que Bolsonaro teve um desempenho superior…” e “reduzindo em mais da metade a pobreza extrema”.

```
prompt = [
('user', 'A seguir apresento **EXEMPLOS** de frases já classificadas como "-1" (citação), "0" (facto), e "1" (viés). Estes são apenas exemplos:'),
# CITACOES
('user', 'Se não passou, vamos colocar as alternativas seguintes", disse.'),
('assistant', '-1'),
```

Figura 14 - Estrutura de uma frase de exemplo passada na prompt

```
prompt = [
    ('system', 'Você é um agente que classifica frases em português com "-1" (CITAÇÃO), "0" (FACTO) ou "1" (VIÉS). Responda *apenas com o número na primeira linha*.\n\n'
     '0 (FACTO): Informação apresentada de forma imparcial, centrada em factos objetivos.\n'
     '1 (VIÉS): Informação tendenciosa, apresentando um ponto de vista parcial ou influenciado.\n'
     '-1 (CITAÇÃO): Declarações diretas, geralmente entre aspas, usadas por jornalistas para relatar palavras de alguém envolvido no evento.\n' ),
```

Figura 15 - Estrutura da tentativa do uso de system para a prompt

Inicialmente experimentamos vários prompts que não funcionaram, uma vez que o LLM, na sua resposta, classificava as próprias amostras de exemplo já classificadas, impossibilitando uma leitura correta dos outputs. Também tentámos fazer uso de “system” (como é visível na figura 15), no entanto, só fez o modelo Ollama alucinar mais e continuar a classificar os exemplos de treino que já estavam classificados.

Finalmente decidimos experimentar usar uma pequena explicação das classes, o que o fez alucinar menos e conseguir classificar apenas a última frase de teste como era suposto. Dito isto, ainda experimentámos dois prompts com as primeiras 51 amostras de teste, pois assim conseguimos ter uma noção de qual seria melhor para ser posteriormente usada no conjunto de teste todo, visto que usando o conjunto inteiro demorava cerca de quatro horas.

```
prompt_final.append({"""Classifique a frase APENAS com um dos seguintes números:
            -1 = CITAÇÃO → A frase descreve algo dito por alguém (com ou sem aspas).
                *Inclui verbos como: disse, afirmou, declarou, relatou, escreveu, segundo, de acordo com*

            0 = FACTO → Informação neutra, objetiva, verificável, sem opinião, sem interpretação.
                *A frase NÃO pode conter intenção, contexto interpretado, avaliação, motivo, causa assumida ou linguagem subjetiva.*


            1 = VIÉS → Opinião, interpretação, julgamento, crítica, linguagem subjetiva, atribuição de intenção, causa ou culpa, emoção,
             suposição ou qualquer formulação não puramente factual.

        REGRAS IMPORTANTES:
        - SE houver qualquer verbo que indique fala → classificar como -1 (mesmo sem aspas).
        - SE a frase incluir interpretações como "sob o argumento", "segundo ele", "alega que", "sob a justificativa", "teria", → também deve ser -1.
        - SE não for claramente citação e não for 100% objetiva e verificável, ENTÃO é 1 (nunca 0).
        - NÃO dês explicação.
        - Responde SOMENTE com *-1*, *0* ou *1*.

        Agora classifica a frase: {frase}
        """
    })
```

	precision	recall	f1-score	support
Citação (-1)	0.00	0.00	0.00	17
Facto (0)	0.89	0.77	0.83	31
Viés (1)	0.08	0.67	0.15	3
accuracy			0.51	51
macro avg	0.32	0.48	0.33	51
weighted avg	0.55	0.51	0.51	51

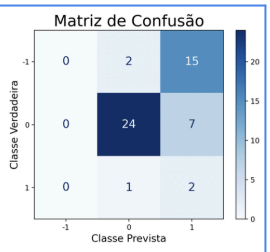

Figura 16 - Primeiro Prompt, Matriz de Confusão e Classification Report

Tentámos usar descrições diferentes das usadas anteriormente para descrever cada classe, com o intuito de reduzir a quantidade de alucinações por parte do LLM. Também testámos o uso de regras importantes para que o modelo fosse mais rigoroso no momento de classificar a amostra e de enviar a resposta. No entanto, estas imposições revelaram-se pouco efetivas e demasiado complexas, uma vez que o modelo alucinou ainda mais, não identificando nenhuma citação e classificando-as quase todas como viés, classe que também não obteve bons resultados. O uso de frases negativas ou a presença da palavra “não” não provou ser vantajoso, trazendo ainda mais dificuldades para o LLM.

```
prompt_final.append(("user",
                     f"""As frases podem estar classificadas com um dos seguintes números:
                     -1 (CITAÇÃO): Declarações diretas, geralmente com pelo menos uma aspa.
                     0 (FACTO): Informação apresentada de forma imparcial, centrada em factos objetivos.
                     1 (VIÉS): Informação tendenciosa, apresentando um ponto de vista parcial ou influenciado.

                     Classifica a frase seguinte dizendo apenas o número correspondente: {frase}"""
                     ))
```

```
Relatório de classificação:
              precision    recall  f1-score   support

Citação (-1)       1.00      0.06      0.11        17
   Facto (0)       0.75      0.97      0.85        31
    Viés (1)       0.10      0.33      0.15         3

    accuracy                           0.63        51
   macro avg       0.62      0.45      0.37        51
weighted avg       0.80      0.63      0.56        51
```

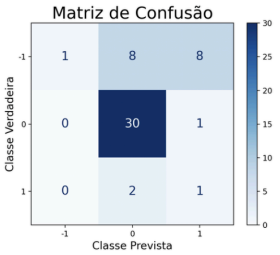

Figura 17 - Segundo Prompt usado com explicação das classes, Matriz de Confusão e Classification Report

Usámos as descrições baseadas no artigo e pedimos ao LLM para responder apenas com o número da classe correspondente, para conseguirmos obter os resultados corretamente, verificando qual número da classe estava presente na resposta. **O segundo prompt** (figura 17) deu melhores resultados: accuracy mais alta, e com todos os valores de F1-score das três classes superiores **ao primeiro prompt** (figura 16). Dito isto, foi usado o segundo prompt para o conjunto de teste total.

```
Relatório de classificação:
              precision    recall  f1-score   support

Citação (-1)       0.70      0.17      0.27       398
   Facto (0)       0.76      0.95      0.85      1258
    Viés (1)       0.15      0.15      0.15       166

    accuracy                           0.71      1822
   macro avg       0.54      0.42      0.42      1822
weighted avg       0.69      0.71      0.66      1822
```

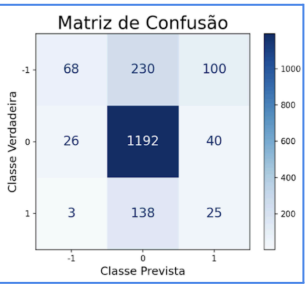

Figura 18 - Prompt usado

Podemos perceber pela figura 18 que obtivemos bons resultados com 71% de accuracy. No entanto, o valor de F1-score das classes citação e viés continuam baixos, 27% e 15% respetivamente. Com esta abordagem, usando exemplos de treino (few-shot), obtivemos resultados significativamente melhores do que usando o zero-shot. Por fim, o modelo confunde a classe facto com as duas restantes, parecendo dar mais importância a esta classe, mesmo tendo exemplos de facto (com percentagens, datas e informações numéricas) bastante distinguíveis dos exemplos das outras classes. Isto talvez possa estar relacionado com o facto da descrição desta classe ser mais generalizável e confundida com outras frases.

4. Chain-of-Thoughts

Tivemos imensos problemas nesta abordagem com prompts iniciais, pois o modelo não segue sempre a mesma estrutura de resposta, gerando dificuldades em obter a classe, pois ele alucinava muito e respondia com uma classe mesmo o seu raciocínio sendo totalmente contraditório a explicar o porquê de ter escolhido outra classe (como é possível observar nas imagens da pasta “Prompts” no zip entregue). Este tipo de situação ocorreu muitas vezes ao longo das 897 amostras.

Experimentámos várias prompts inicialmente, pedindo não só o número da classe da frase como também uma breve explicação do seu raciocínio. Para além disso, testámos pedir-lhe que respondesse antes com a primeira letra da classe em vez do número, e que mostrasse o seu raciocínio primeiro, o que não se mostrou ser um método eficaz, pois o modelo não segue facilmente regras de estrutura e ordem de resposta. Estas tentativas de prompt engineering estão nas imagens da pasta “Prompts” no zip entregue. Finalmente, testámos um prompt em que pedíamos que o modelo respondesse em formato json como é visível na figura 19. Desta forma o modelo já não alucinava e nem se contrariava no seu raciocínio e na classe que atribuiu à frase. Infelizmente, devido ao tempo estimado de 15 horas que demoraria este modelo, só conseguimos apresentar resultados das primeiras 897 amostras das 1822 amostras totais de treino.

É importante destacar que, no pós-processamento, a classe foi determinada verificando a presença de “v”, “f” ou “c” na resposta. Caso nenhuma dessas letras aparecesse, a frase era classificada como facto, por ser a classe maioritária, evitando assim exceções. Ao usar JSON, as respostas seguiram sempre a mesma estrutura e não houve alucinações, o que tornou este pós-processamento um procedimento suficiente para extrair corretamente as classes de cada resposta.

```
{"classe": "c", "racionio": "A frase relata algo que alguém disse, afirmou, declarou ou escreveu, especificamente a diretora da Anac Denise Abreu."}
```

```
{"classe": "f", "racionio": "A frase relata um evento verificável e objetiva, sem opinião ou linguagem subjetiva."}
```

```
{"classe": "v", "racionio": "A frase expressa uma opinião pessoal do autor, utilizando linguagem subjetiva e emocional ('importantíssimo') que não é verificável ou
 objetiva."}
```

Figuras 19, 20 e 21- Exemplos de Respostas do LLM em Formato JSON de cada classe

Podemos perceber imediatamente pela Matriz de Confusão (figura 22), que houve imensos falsos positivos tanto na classe viés como na citação, mesmo tendo uma accuracy. Os valores de F1-score nas classes viés e citação foram relativamente melhores comparativamente às abordagens anteriores.

Esta abordagem beneficiaria de exemplos representativos de cada classe (few-shot), no entanto por motivos de falta de tempo, não foi possível testar essa estratégia.

```
prompt = (
"""Classifique a frase em uma das três categorias:
    CITAÇÃO (c)
    FACTO (f)
    VIÉS (v)

    REGRAS:
    - CITAÇÃO (c): A frase relata algo que alguém disse, afirmou, declarou ou escreveu.
    - FACTO (f): Informação objetiva, verificável, sem opinião.
    - VIÉS (v): Opinião, julgamento, interpretação, emoção ou linguagem subjetiva.

    Agora classifica esta frase (como c, v ou f) e Retorna *APENAS* JSON no formato {"classe": ?, "raciocinio": "..."}: """
)
```

```
Relatório de classificação:
              precision    recall  f1-score   support

Citação (-1)       0.38      0.36      0.37       198
   Facto (0)       0.93      0.47      0.62       615
    Viés (1)       0.16      0.76      0.27        84

    accuracy                           0.47       897
   macro avg       0.49      0.53      0.42       897
weighted avg       0.73      0.47      0.53       897
```

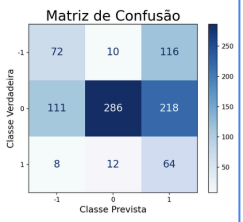

Figura 22 - Prompt usado, Matriz de Confusão e Relatório de Classificação

5. Discussão

Ao analisar os resultados de todas as abordagens, concluímos que a Few-shot foi a que teve melhor desempenho, obtendo a accuracy mais alta de 71%. Já o Zero-shot e o Chain-of-Thoughts, obtiveram 39% e 47%, respetivamente. No entanto, através de Chain-of-Thoughts alcançámos um dos valores mais elevados de F1-score nas duas classes mais difíceis de identificar: Citação (37%) e Viés (27%), mas à custa de termos mais falsos positivos. Todavia, esta abordagem não é totalmente comparável às restantes, por se ter baseado em apenas 897 amostras das 1822 de teste. O mesmo aconteceu com Zero-shot, obtendo o F1-score mais elevado na classe citação de valor 41%, mas havendo muitos falsos positivos nesta classe. No Few-shot, apesar de termos accuracy alta, obtemos F1-scores das classes citação, facto e viés com valores 27%, 85% e 15% respetivamente, o que revela uma enorme dificuldade em detetar as duas classes mais pequenas. Foi possível perceber que, mesmo não tendo resultados excelentes na abordagem Few-shot, esta foi preferível a uma abordagem que não fornece nenhum tipo de exemplo (como no zero-shot). Com um prompt que forneça uma pequena descrição de cada classe ao LLM, obtivemos melhores resultados do que ao não o fazer. Adicionalmente, percebemos que prompts mais simples, diretos e sem teor negativo tendem a obter respostas mais de acordo com o que foi pedido.

6. Comparação com as outras metas

	precision	recall	f1-score	support
-1	0.76	0.61	0.68	417
0	0.82	0.77	0.79	1273
1	0.20	0.39	0.26	168
accuracy			0.70	1858
macro avg	0.59	0.59	0.58	1858
weighted avg	0.75	0.70	0.72	1858

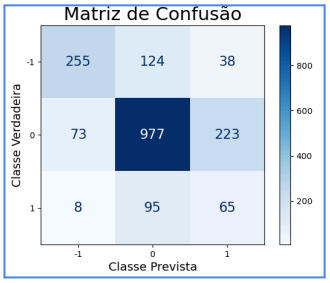

Figuras 23 e 24 - Matriz de confusão do conjunto de regras

Relatório de classificação:

	precision	recall	f1-score	support
Citação (-1)	0.88	0.90	0.89	417
Facto (0)	0.91	0.94	0.92	1273
Viés (1)	0.59	0.40	0.48	168
accuracy			0.88	1858
macro avg	0.79	0.75	0.76	1858
weighted avg	0.87	0.88	0.87	1858

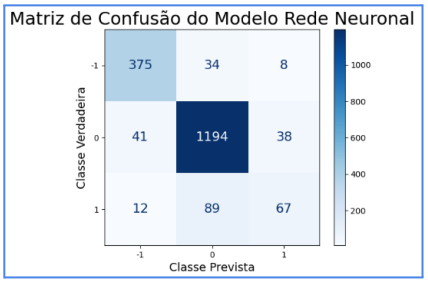

Figuras 25 e 26 - Matriz de Confusão do BERT nas redes neuronais

Relatório de classificação:

	precision	recall	f1-score	support
Citação (-1)	0.70	0.17	0.27	398
Facto (0)	0.76	0.95	0.85	1258
Viés (1)	0.15	0.15	0.15	166
accuracy			0.71	1822
macro avg	0.54	0.42	0.42	1822
weighted avg	0.69	0.71	0.66	1822

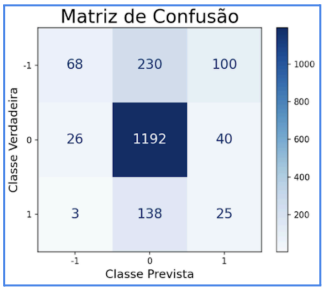

Figuras 27 e 28 - Resultados do Few-shot

Podemos perceber automaticamente que, na Meta 2, utilizando o modelo BERT nas redes neuronais obtivemos o melhor desempenho em todas as métricas, comparativamente às outras duas metas. Este modelo obteve uma accuracy de 88% enquanto que o LLM e as nossas regras obtiveram 71% e 70%, respetivamente. Reparámos ainda que as nossas regras conseguiram detetar melhor as frases de citação e viés do que o LLM, obtendo valores de F1-score de 68% e 26% respetivamente, já o LLM obteve 27% e 15% respetivamente. Também notamos que a classe facto foi melhor detetada pela Rede Neuronal com o BERT (detetou 1194 amostras) e pelo LLM Ollama (detetou 1192 amostras) do que pelas nossas regras que só detetaram 977 das 1822 frases.

7. Conclusão

Através deste trabalho foi-nos possível compreender o quão complexo é o processo de distinção de frases utilizando regras linguísticas construídas de raiz. Para além disso, possibilitou a aprendizagem de diferentes tipos de representação textual (TF-IDF, GloVe e BERT), bem como uma revisão de conhecimentos acerca de todos os modelos existentes e dos testes de parâmetros usando Optuna. Por último, permitiu explorar aspetos relevantes de prompt engineering e compreender os desafios inerentes à integração de modelos generativos em tarefas de classificação.

Uma das maiores dificuldades com que nos deparámos ao longo de todo este trabalho, está relacionada com, não só o desbalanceamento do dataset, mas também com o facto de existirem frases que achamos que estão mal classificadas no próprio dataset, ou que apenas se saberia que pertenceriam a uma classe através do contexto em que se inserem no artigo. Um exemplo é a frase: “Não reajusta a merenda escolar, mas gasta milhões com leite condensado;” que nós classificaríamos como viés (1) mas que está como citação (-1) no dataset. Após alguma pesquisa foi possível concluir que essa frase fazia parte de uma citação, mas sem contexto, seria impossível saber. Outro obstáculo foi trabalhar com o LLM, uma vez que dava sempre respostas com uma estrutura diferente da desejada, impossibilitando a classificação correta da frase.

Referências:

- https://realpython.com/python-nltk-sentiment-analysis/
- https://realpython.com/sentiment-analysis-python/
- https://www.kaggle.com/code/krutarthhd/sentiment-classification-using-spacy
- https://www.linkedin.com/pulse/spacy-sentiment-analysis-easy-way-analyze-text-vitor-mesquita-zo83f
- https://spacy.io/usage/spacy-101
- https://spacy.io/api/textcategorizer
- https://wandb.ai/authors/Kaggle-NLP/reports/Kaggle-s-NLP-Text-Classification--VmlldzoxOTcwNTc
- https://spacy.io/models/pt
- https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.CountVectorizer.html
- https://medium.com/@johnidouglasmarangon/building-a-text-classification-model-with-spacy-3-x-57e59fa50547
- https://www.nltk.org/howto/wordnet.html